Facteurs de risque cervicaux

Analyse Python expliquée, du fichier brut au test réservé

Projet pédagogique - UE 5BM753 - données fournies : 858 dossiers, 36 colonnes. Analyse réalisée le 13 septembre 2026. Code et rédaction préparés avec assistance ChatGPT/Codex. Tous les résultats ci-dessous proviennent de l'exécution des scripts sur le CSV fourni. Aucune contribution humaine individuelle n'est inventée.

Le résultat à retenir

Les facteurs disponibles permettent d'explorer des profils de patientes, mais les deux modèles étudiés ne démontrent pas une capacité de prédiction suffisante sur le test réservé. La forêt, sélectionnée en validation croisée, atteint une AP test de 0.082, proche de la référence naïve (0.065). Au seuil choisi en développement, elle détecte 2 biopsies positives sur 14, avec 28 faux positifs.

Le clustering produit 5 profils stables autour de cet échantillon, mais leur séparation reste modeste. La vue PCA en deux dimensions ne conserve que 41.2 % de la variance. Ces groupes décrivent des caractéristiques de dossiers ; ils ne constituent pas des sous-types de cancer.

Ce rapport explique les choix, les résultats et ce qu'ils ne permettent pas d'affirmer. Les guides du dossier `09_resources/01_documentation` détaillent ensuite le code.

1. Définir une question que les données peuvent résoudre

La source UCI décrit un recueil à l'Hospital Universitario de Caracas, au Venezuela, avec informations démographiques, habitudes et antécédents [R1]. Une ligne représente un dossier. Nous ne disposons pas d'un suivi temporel exploitable, d'un identifiant de patiente ni d'une date permettant d'ordonner des visites. La question est donc la classification d'un résultat de biopsie, pas la prévision d'un cancer futur.

L'OMS situe l'infection persistante par un HPV à haut risque au cœur de la biologie du cancer du col [R2-R3]. Cette connaissance motive le contexte. Elle ne transforme pas le champ `STDs:HPV` de ce fichier en une mesure validée de cette persistance. Les modes de recueil et la chronologie des variables ne sont pas assez détaillés pour établir des effets causaux des facteurs observés.

Nous choisissons `Biopsy`, codée 0/1, comme unique cible. Les quatre examens du fichier sont des cibles distinctes : Hinselmann, Schiller, Citology et Biopsy. Le détail histologique de la positivité n'est pas fourni. Nous utilisons donc l'expression « biopsie positive » et n'assimilons pas chaque 1 à un cancer invasif. Le critère 1 reste une étiquette de la base, sans définition clinique supplémentaire inventée.

La seconde question est descriptive : retrouve-t-on des ensembles de profils similaires sans fournir la biopsie à l'algorithme ? Le supervisé et le non supervisé répondent ainsi à des questions complémentaires, avec des évaluations différentes.

2. Examiner le fichier avant le modèle

Le CSV contient 55 biopsies positives et 803 négatives : 6,41 % de positivité. La moyenne d'âge est 26,82 ans, la médiane 25 ans et l'étendue 13-84 ans. Le fichier comporte 3 622 cellules manquantes. Les quatre cibles n'ont pas d'absence, mais de nombreuses caractéristiques sont incomplètes.

Contrôle	Constat sur le fichier fourni	Décision
Délais depuis diagnostic d'IST	787 absences sur 858 pour chacun	Exclure ces deux champs
Répétitions exactes sur 36 colonnes	23 répétitions au-delà de la première occurrence	Conserver, puis grouper les profils
Premier rapport après l'âge déclaré	Deux dossiers : 23/27 ans et 14/16 ans	Rendre le premier rapport manquant
Âges ou comptes très élevés	Valeurs inhabituelles, pas de preuve d'erreur	Conserver et décrire
Colonnes binaires hors 0/1	Aucune parmi celles contrôlées	Codage utilisable
Suppression de toutes les lignes incomplètes	Seulement 59 dossiers complets sur les 36 colonnes	Éviter cette stratégie globale

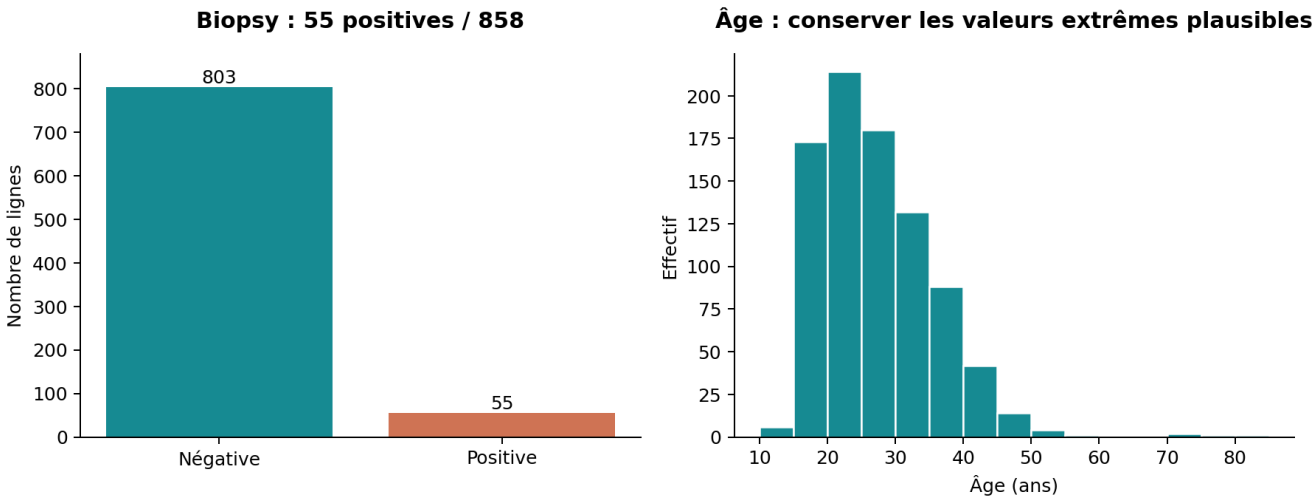


Figure 1. Déséquilibre de la cible et distribution de l'âge dans les 858 dossiers. Source : 01_cibles.csv et données brutes.

Le nettoyage ne prétend pas connaître l'âge correct dans les deux dossiers incohérents. Conserver l'âge et rendre le premier rapport manquant est une convention prudente, traçable dans `01_anomalies.csv`. Les patientes restent dans l'analyse. Les 23 répétitions exactes ne sont pas supprimées arbitrairement, car deux patientes peuvent partager les mêmes informations.

La source UCI mentionne des refus de réponse pour des raisons de confidentialité. Cela rend injustifiée l'affirmation que les absences seraient complètement aléatoires. La cartographie complète des absences est disponible dans `01_description_variables.csv` et `01_valeurs_manquantes.png`.

3. Préparer les variables pour un scénario avant examens

Nous excluons la cible, les trois autres résultats d'examen, les quatre variables Dx et les deux délais très incomplets. Les variables Dx pourraient être des antécédents utiles si leur disponibilité avant l'examen était prouvée. Ici, la documentation ne permet pas de garantir ce moment. L'exclusion est une protection liée au scénario, pas une preuve qu'elles constituent effectivement une fuite.

Il reste 26 prédicteurs candidats, dont dix numériques et seize binaires. Sept indicateurs d'absence sont ajoutés, à raison d'un par domaine de recueil. Les constantes sont retirées dans chaque apprentissage. Dans le développement complet, 5 colonnes sont constantes après préparation : STDs:cervical condylomatosis, STDs:pelvic inflammatory disease, STDs:molluscum contagiosum, STDs:AIDS, STDs:Hepatitis B. Après ajout des indicateurs et retrait de ces constantes, le modèle reçoit 28 entrées. Les colonnes retirées peuvent différer dans un pli ; cette adaptation fait partie du pipeline.

La sélection ne repose pas sur des tests univariés avec la cible. Avec seulement 41 positives en développement, une recherche extensive de variables serait fragile. Nous préférons un ensemble motivé par le scénario et une complexité limitée. La régularisation L2 réduit les coefficients logistiques sans réaliser une sélection parcimonieuse comme le ferait une pénalisation L1.

Les comptes et durées sont transformés par log1p, soit ln(1+x). Le zéro est conservé et les fortes valeurs sont comprimées. Les deux âges restent bruts. Cette transformation suppose une relation dans cet espace pour la logistique et change la géométrie du clustering ; elle n'est pas présentée comme une loi biologique. Elle ne dépend d'aucune statistique apprise et peut donc précéder le découpage.

Les numériques sont imputés par médiane ou moyenne dans l'espace transformé. Les binaires sont imputés par leur mode. Le choix moyenne/médiane est comparé en validation croisée. Les numériques sont standardisés pour la logistique ; la forêt n'en a pas besoin. Les binaires et indicateurs restent 0/1. Les traitements appris sont tous placés dans un pipeline [R4-R5].

Les valeurs imputées sont des moyens de calculer, pas des réponses retrouvées. Cette approche simple ne propage pas toute l'incertitude d'imputation et peut créer des combinaisons peu plausibles entre champs. Les indicateurs d'absence préservent une partie du contexte, mais peuvent aussi encoder les pratiques locales de recueil. Nous examinons leur influence par une analyse de sensibilité.

4. Séparer développement et évaluation finale

Les 858 dossiers sont répartis en 643 lignes de développement, dont 41 positives, et 215 lignes de test, dont 14 positives. Le premier pli d'un découpage stratifié par groupes à quatre plis est réservé comme test, avec la graine 42 [R6]. Ce pli est fixé avant calcul des performances, et nous ne recherchons pas un tirage favorable.

Les profils identiques sur les 26 prédicteurs restent ensemble. Cela donne 831 groupes de profils, avec 27 répétitions de profil au-delà de la première occurrence. Ces groupes ne sont pas des identifiants de patientes. Cette précaution conservatrice évite qu'un même profil se retrouve des deux côtés d'une séparation, mais ne permet pas de garantir l'indépendance biologique des dossiers.

Dans le développement, cinq plis stratifiés par groupes servent à sélectionner les réglages. Chacun comporte huit ou neuf positives pour la validation. À chaque apprentissage,

imputation, standardisation et constantes sont réapprises uniquement sur les quatre plis d'entraînement. La ligne de validation ne participe pas à ces calculs. Les assertions et tests contrôlent l'absence de groupe partagé.

Les scores de sélection CV peuvent être optimistes car le meilleur réglage est choisi parmi plusieurs essais. Nous n'utilisons pas une validation imbriquée pour estimer ce processus par CV ; nous réservons une épreuve finale séparée. Le protocole est consigné dans `00_protocole_avant_resultats.md`, après l'audit du fichier et avant les calculs de performance, sans revendiquer de préenregistrement formel.

5. Deux classifieurs et une référence

La référence `DummyClassifier(strategy="prior")` produit pour toutes les lignes la proportion positive apprise. Elle n'utilise aucun facteur de risque et prédit la classe négative au seuil 0,5. Un modèle de persistance, pertinent pour certaines séries temporelles, n'est pas défini avec ces dossiers sans suivi.

La régression logistique L2 calcule une somme pondérée des entrées puis la transforme en score entre 0 et 1. Elle sert de modèle additif interprétable. Nous comparons C=0,1 et C=1 ; un plus petit C renforce la régularisation [R7]. La forêt de classification ajoute la possibilité de seuils et d'interactions. Nous fixons 200 arbres et une profondeur maximale de cinq, et comparons des feuilles minimales de cinq ou quinze lignes [R8].

Chaque famille compare aussi les deux imputations et la pondération absente ou `balanced`. Il y a donc huit configurations par famille, soit seize configurations au total, toutes évaluées sur les mêmes cinq plis. Nous n'ajoutons pas une liste de SVM, XGBoost ou réseaux neuronaux : la question est de comparer un modèle additif à un modèle non linéaire avec une évaluation approfondie.

La pondération modifie l'apprentissage en augmentant le poids de la classe rare. Elle ne change pas les effectifs et n'est pas imposée comme forcément supérieure. Le seuil modifie ensuite la décision à partir du score, sans changer le classement. Le projet étudie ainsi le déséquilibre sans ajouter de patientes synthétiques.

6. Choisir les scores et le seuil

L'AP, average precision, est le critère principal. Elle résume la précision obtenue à mesure que l'on récupère davantage de positives. Elle est différente de l'aire trapézoïdale de la courbe précision-rappel [R9]. Pour la référence à score constant, elle égale la fraction positive du jeu évalué. La ROC-AUC reste un indicateur complémentaire de discrimination, sans remplacer l'AP.

Mesure	Question posée
Rappel / sensibilité	Quelle fraction des biopsies positives est repérée ?
Précision / VPP	Quelle fraction des alertes correspond à une biopsie positive ?
Spécificité	Quelle fraction des biopsies négatives est classée négative ?
Balanced accuracy	Quelle est la moyenne sensibilité/spécificité ?
F1, F2	Quel compromis entre rappel et précision au seuil donné ?

Mesure	Question posée
Brier	Les scores sont-ils proches des réponses 0/1, en moyenne quadratique ?
MCC	Existe-t-il une association entre observations et classes prédites ?

Le seuil de chaque classifieur maximise F2 sur les prédictions hors pli (OOF) du développement. F2 donne davantage de poids au rappel que F1 ; c'est ici un choix pédagogique, sans coût clinique estimé. Les hyperparamètres ayant été choisis à l'aide de ces plis, ces OOF ne fournissent pas une validation indépendante du seuil. Seul le test réservé évalue la règle complète une fois fixée.

Les matrices de confusion exposent les vrais/faux positifs et négatifs. Lorsque le modèle ne fait aucune alerte, la précision est indéfinie ; le code la remplace conventionnellement par zéro avec `zero_division=0`. Tous les modèles sont aussi évalués au seuil 0,5 pour que l'effet du seuil soit visible.

7. Résultats de validation et choix du modèle

Modèle	AP CV	Écart-type	AP apprentissage	ROC-AUC CV
Base	0.064	0.003	0.064	0.500
Logistique	0.135	0.029	0.225	0.622
Foret	0.217	0.036	0.525	0.665

Source : `02_comparaison_cv.csv`. L'écart-type décrit les cinq plis ; il ne constitue pas un intervalle de confiance. La forêt est sélectionnée avant le test. Son AP d'apprentissage bien supérieure à l'AP de validation indique une adaptation aux données d'entraînement qui se généralise imparfaitement.

La logistique retient C=1, l'imputation moyenne et l'absence de pondération. La forêt retient cinq lignes minimales par feuille, la médiane et l'absence de pondération. Les meilleures AP CV pour chaque combinaison sont les suivantes. Les deux réglages de complexité sont départagés à l'intérieur de chaque ligne.

Famille	Poids	Imputation	Meilleure AP CV
Logistique	sans	median	0.134
Logistique	sans	mean	0.135
Logistique	balanced	median	0.132
Logistique	balanced	mean	0.132
Foret	sans	median	0.217
Foret	sans	mean	0.216
Foret	balanced	median	0.186

Famille	Poids	Imputation	Meilleure AP CV
Foret	balanced	mean	0.189

Les différences moyenne/médiane restent petites dans ce protocole. La pondération `balanced` ne donne pas le meilleur classement des positives en CV. Retirer les indicateurs d'absence du classifieur choisi, sans nouveau réglage, donne une AP CV moyenne de 0.216. Cette sensibilité n'établit pas leur utilité et ne sert pas à lancer une nouvelle sélection après examen du test.

8. Résultats sur le test réservé

Modèle	Seuil	AP	ROC_AUC	Rappel	Précision	Spécificité
Base	0.500	0.065	0.500	0.000	0.000	1.000
Logistique	0.078	0.086	0.527	0.357	0.106	0.791
Foret	0.116	0.082	0.572	0.143	0.067	0.861

Source : `02_metriques_test.csv`. La base garde son seuil 0,5 ; les autres lignes utilisent le seuil F2 OOF. Le test contient la prévalence observée 0.065. Le modèle sélectionné en CV est conservé comme analyse principale malgré la légère inversion de classement en AP sur ce test. Nous ne réécrivons pas le choix a posteriori.

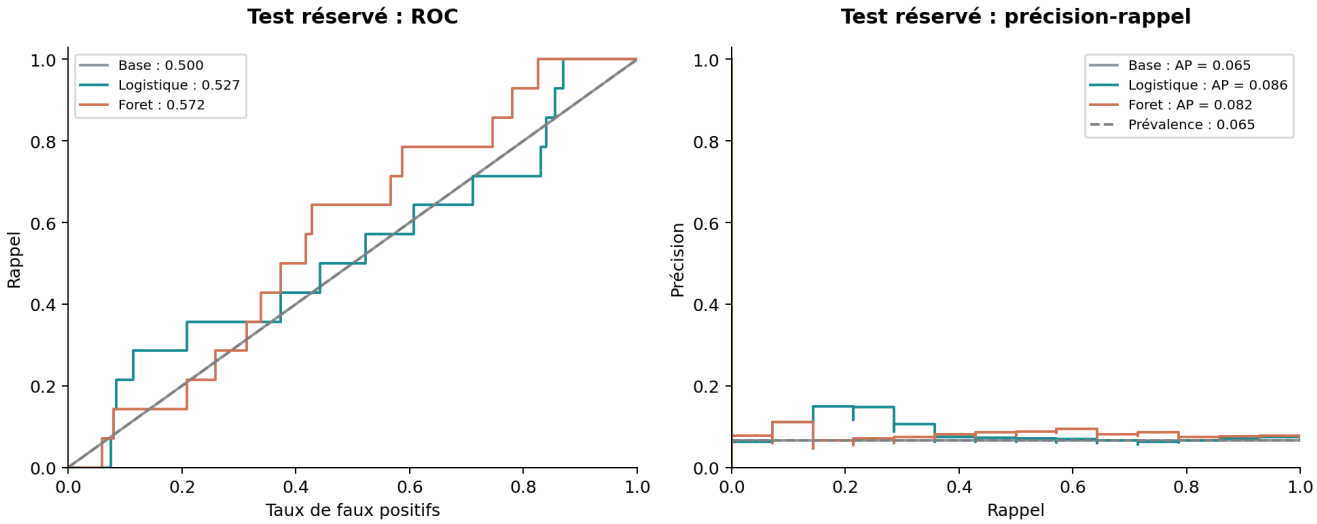


Figure 2. Discrimination sur les 215 lignes de test : ROC et précision-rappel. Les scores sont ceux des modèles ajustés sur le développement.

Au seuil 0,5, la base et les deux classifieurs prédisent toutes les biopsies négatives. Ils obtiennent donc 93,49 % d'accuracy, mais un rappel nul. La balanced accuracy vaut 0,5. Une présentation centrée sur l'accuracy masquerait cet échec de détection des positives.

Modèle	TP	FP	FN	TN	F1	F2	MCC
Base	0	0	14	201	0.000	0.000	0.000
Logistique	5	42	9	159	0.164	0.243	0.088
Foret	2	28	12	173	0.091	0.116	0.003

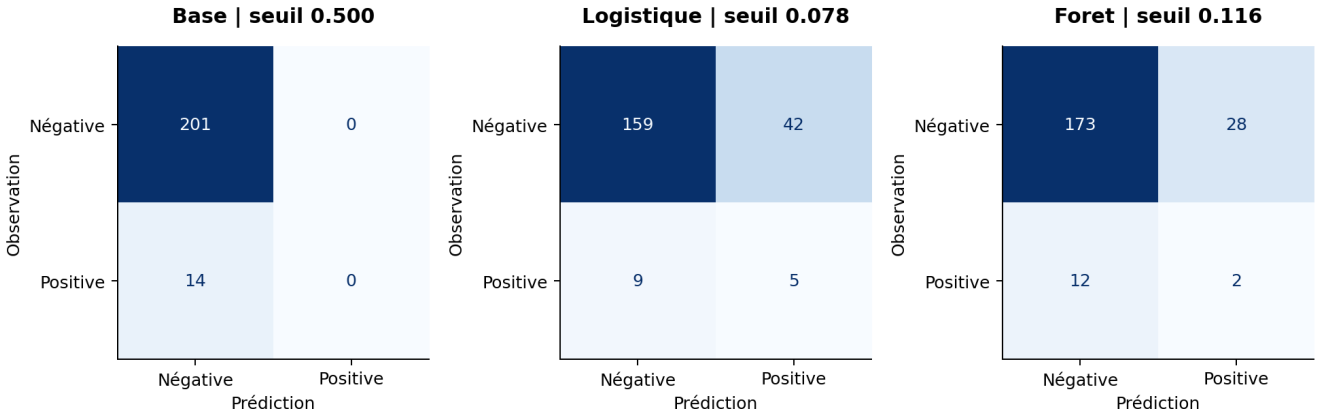


Figure 3. Matrices de confusion aux seuils figés en développement. Les observations sont en lignes, les prédictions en colonnes.

La forêt sélectionnée atteint un rappel de 14.3 % et une précision de 6.7 %. Le changement de seuil crée des alertes, mais il ne répare pas un classement peu informatif. La logistique repère davantage de positives à son propre seuil, au prix de davantage de faux positifs. Les deux règles restent insuffisantes pour une décision de dépistage.

9. Incertitude, calibration et interprétation

Un bootstrap par groupes du test, avec 1 000 tirages, donne les intervalles approximatifs suivants pour la forêt sélectionnée. Les modèles et seuils restent fixes pendant ces tirages. Les intervalles ne couvrent pas la variabilité de tout le processus d'apprentissage ni le passage à un autre hôpital.

Mesure	Estimation	Borne 2,5 %	Borne 97,5 %
AP	0.082	0.046	0.159
ROC_AUC	0.572	0.434	0.708
recall	0.143	0.000	0.333
specificity	0.861	0.812	0.909
precision	0.067	0.000	0.161
F2	0.116	0.000	0.266
Brier	0.064	0.036	0.096

La différence appariée d'AP forêt moins base vaut 0.016, avec un intervalle allant de -0.002 à 0.087. Cet intervalle inclut zéro. Nous n'avons pas une preuve robuste d'amélioration sur la base dans cette évaluation. Le test ne contient que 14 positives : une patiente modifie le rappel de 7,14 points.

Le Brier de la forêt vaut 0.0635, contre 0.0609 pour la base. Le Brier, à minimiser, est un score probabiliste global et non une mesure pure de calibration. La courbe de calibration regroupe les scores en cinq groupes de taille voisine, avec les effectifs exacts exportés [R10]. Ces petits nombres de positives limitent fortement sa précision.

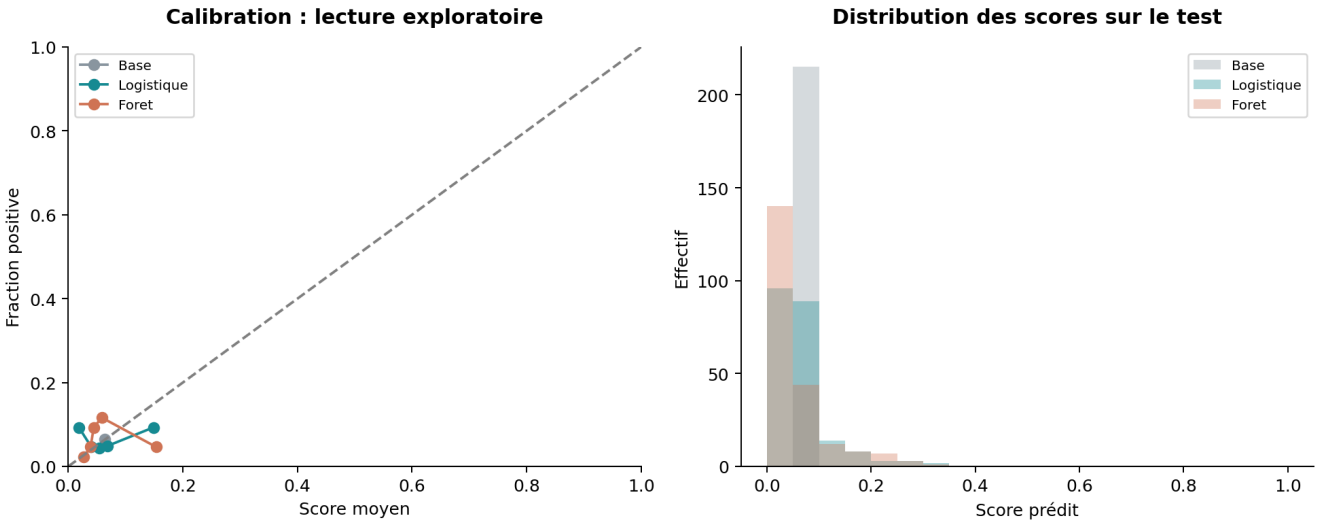


Figure 4. Calibration exploratoire et distribution des scores sur le test. Les effectifs par point figurent dans 02_calibration_bins.csv.

Les coefficients logistiques sont pénalisés et dépendent des autres variables. Une unité correspond à un écart-type pour une numérique et au passage 0/1 pour une binaire ; leur classement par taille n'est pas une comparaison homogène d'effets biologiques. L'importance par permutation mesure la baisse d'AP lorsqu'une colonne est mélangée sur le test. Elle dépend de la performance du modèle et des redondances entre variables [R13]. Les résultats sont exportés pour transparence, mais leur faiblesse et leur instabilité interdisent de déclarer des facteurs causaux ou des marqueurs prédictifs validés.

10. Explorer les profils avec PCA et k-means

Le clustering utilise huit mesures : âge, âge au premier rapport, partenaires, grossesses, années de tabagisme, années de contraception hormonale, années de DIU et nombre d'IST. Les binaires rares sont écartés de la distance et certaines mesures redondantes ne sont pas répétées. Ce choix définit une exploration de profils numériques, pas une partition exhaustive de toutes les données mixtes.

Log1p, médiane et standardisation préparent cet espace. Les statistiques sont apprises sur le développement, puis appliquées au test. K-means minimise les distances au carré aux centres [R11]. Il est ajusté sur les huit dimensions, avec vingt initialisations pour chaque k de deux à cinq. Une solution est admissible si chaque groupe contient au moins 5 % du développement.

k	Taille min	Taille max	silhouette	CH	DB
2	297	346	0.200	126.103	2.038
3	70	323	0.221	122.169	1.766
4	49	297	0.228	127.250	1.560
5	43	279	0.247	132.694	1.402

Le meilleur k dans cette grille est 5. Le maximum se trouve à sa borne supérieure : nous ne prouvons pas que cinq soit un optimum universel. Le seuil minimal de taille est une règle pragmatique de lisibilité, sans fondement biologique particulier. L'inertie est exportée mais sa diminution mécanique avec k ne suffit pas à établir l'existence de groupes naturels.

La silhouette compare la cohésion d'un groupe à sa séparation du voisin le plus proche. Une valeur proche de zéro indique du chevauchement. Ici, la silhouette est 0.247 sur le développement et 0.232 sur le test affecté aux centres appris. La séparation reste donc modeste. CH et DB sont des indices complémentaires, et CH ne doit pas être comparé naïvement entre échantillons de tailles différentes.

11. La PCA montre une partie de l'information

La PCA construit des axes qui expliquent la variance des entrées, sans connaître la biopsie [R12]. PC1 explique 24.05 % et PC2 17.15 %, soit 41.19 % ensemble. Il faut 7 composantes pour dépasser 90 %. L'erreur de reconstruction sur deux axes est également exportée.

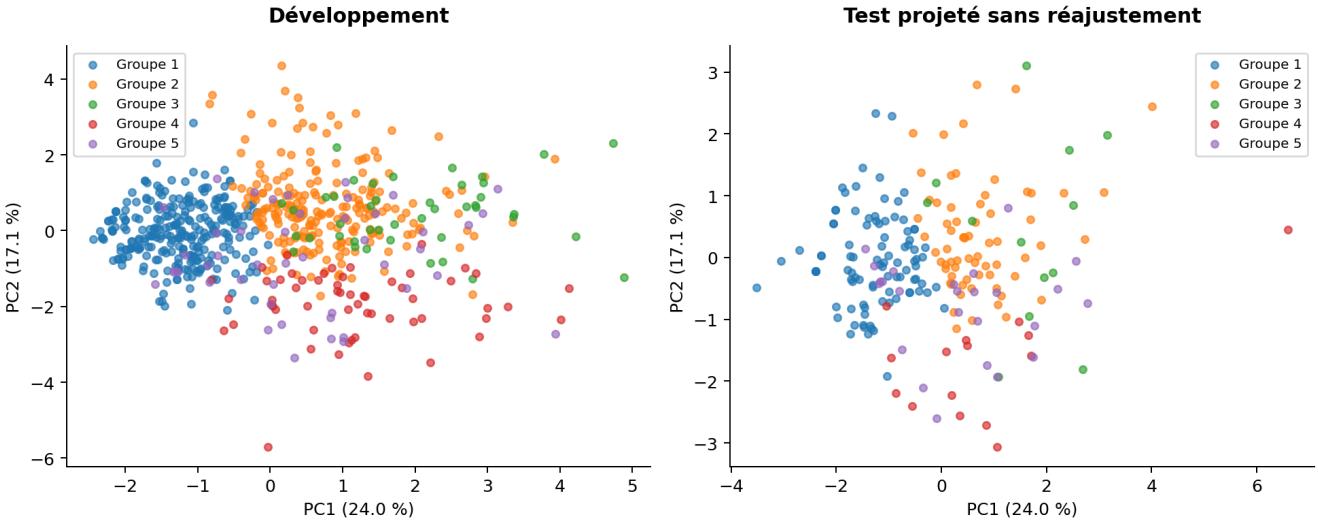


Figure 5. PCA du développement et projection du test. Les couleurs viennent du k-means appris sur les huit dimensions, et non sur ces deux axes seulement.

Un chevauchement en 2D n'invalide pas à lui seul toute structure dans l'espace complet, et une séparation apparente en 2D ne prouverait pas une séparation clinique. C'est la raison de combiner la visualisation à une silhouette calculée dans l'espace effectivement utilisé par k-means.

La stabilité réapprend toute la préparation et k-means sur vingt sous-échantillons de 80 % des groupes de profils du développement. Chaque solution réaffecte ensuite toutes les lignes de développement. L'ARI moyen avec la partition de référence vaut 0.954. C'est une robustesse locale autour de données qui se recouvrent, pas une preuve externe.

Variante	ARI	silhouette	CH	DB
mean_imputation	0.935	0.237	130.232	1.409
clip_1_99_percent	0.951	0.252	135.941	1.396

La moyenne d'imputation et l'écrêtage aux quantiles 1/99 % modifient assez peu la partition. Cette stabilité coexiste avec une séparation modeste : reproduire une partition ne démontre pas qu'elle corresponde à des catégories biologiques nettes.

12. Interpréter les groupes sans leur attribuer un diagnostic

Les médianes observées décrivent un premier profil plus jeune avec moins de grossesses, un deuxième plus âgé avec davantage de grossesses, un profil marqué par le DIU, un par une durée de tabagisme élevée et un par les IST déclarées. Ces descriptions servent à lire la partition ; les numéros n'ont pas d'ordre de gravité. Les médianes et leurs effectifs observés sont exportés séparément des centres transformés et imputés représentés dans la figure.

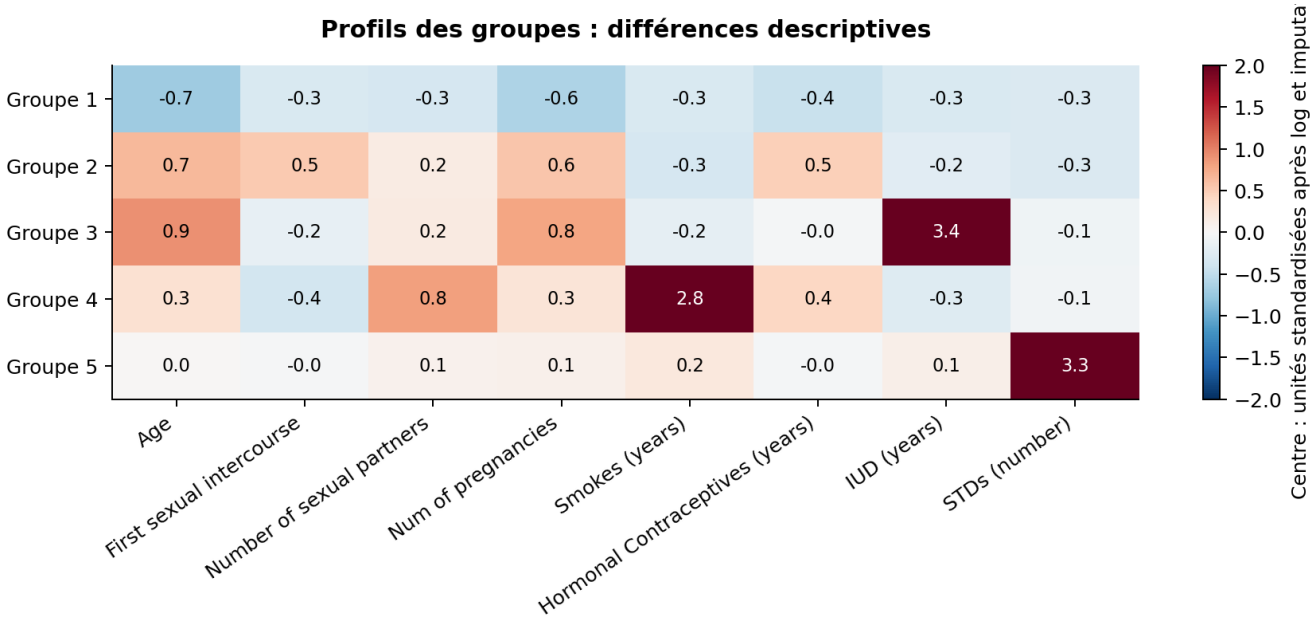


Figure 6. Centres des groupes dans l'espace standardisé. Une valeur élevée signifie plus que la moyenne de développement dans la variable transformée.

Groupe	Effectif	Biopsies +	Fraction +	Sous-ensemble
1	279	11	0.039	development
2	218	11	0.050	development
3	43	6	0.140	development
4	57	5	0.088	development
5	46	8	0.174	development
1	95	5	0.053	test
2	67	4	0.060	test
3	13	1	0.077	test
4	15	2	0.133	test
5	25	2	0.080	test

Les proportions de biopsies positives sont calculées seulement après fixation des groupes. Elles ne servent pas à choisir k. Le groupe 5 compte 8/46 positives en développement mais 2/25 dans le test. Les proportions varient et les effectifs sont faibles. Ces descriptions ne

suffisent pas pour définir des classes de risque. Les taux d'absence par groupe sont aussi exportés pour repérer une contribution possible des pratiques de recueil.

13. Discussion et prolongements raisonnables

Le principal enseignement est la nécessité d'une évaluation séparée : une forêt apparemment meilleure en CV peut fournir un faible signal sur de nouvelles lignes. La taille de l'échantillon positif, la sélection de réglages sur peu de cas, la corrélation des variables, le recueil incomplet et l'absence de mesure précise de certaines expositions peuvent contribuer à cette fragilité. Nous ne pouvons pas attribuer la chute du test à une cause unique avec ce seul découpage.

Le travail de Fernandes et collaborateurs sur la prédiction de la biopsie propose un apprentissage conjoint de représentation et de classification [R14]. Ce projet choisit une comparaison plus simple et interprétable. Nous ne comparons pas des scores publiés sous des cibles, variables et découpages différents. Un résultat élevé ailleurs ne remplace pas une évaluation reproductible du protocole présent.

Les prochaines données les plus utiles seraient une définition histologique précise de la cible, la chronologie des variables `Dx`, les dates et identifiants nécessaires à l'indépendance des dossiers, ainsi qu'une validation dans un autre centre. À protocole refondu, une validation imbriquée pourrait quantifier davantage la variabilité de sélection. Une imputation multivariée/multiple ou une distance adaptée aux variables mixtes seraient des prolongements à évaluer, pas des améliorations garanties.

Il serait incorrect de multiplier les tirages, les modèles ou les seuils jusqu'à obtenir un score test flatteur. Après cette analyse, un changement guidé par les erreurs du test doit être évalué sur de nouvelles données indépendantes. La conclusion retenue reste : profils descriptifs identifiables, capacité prédictive non établie pour un usage clinique.

14. Reproduire et expliquer le travail

Installer `requirements.txt`, puis lancer `python 01_scripts/run_project.py`. Les contrôles se lancent avec `python -m unittest discover -s tests -v`. `00_execution.json` enregistre les versions et la durée. Les données brutes restent intactes.

Le dossier `09_resources/01_documentation` détaille chaque étape et le code. Le support oral et ses notes couvrent dix minutes. Les membres du groupe devront indiquer leurs contributions réelles et maîtriser les choix présentés.

Références

R1. Fernandes, Cardoso, Fernandes (2017). Données UCI et licence.
R2. OMS. Cancer du col de l'utérus.
R3. OMS. Papillomavirus humain et cancer.
R4. scikit-learn 1.8. Bonnes pratiques et fuites.
R5. scikit-learn 1.8. Imputation.
R6. scikit-learn 1.8. StratifiedGroupKFold.
R7. scikit-learn 1.8. LogisticRegression.
R8. scikit-learn 1.8. RandomForestClassifier.
R9. scikit-learn 1.8. Average precision.
R10. scikit-learn 1.8. Calibration.
R11. scikit-learn 1.8. Clustering et évaluation.
R12. scikit-learn 1.8. PCA.
R13. scikit-learn 1.8. Importance par permutation.

R14. Fernandes et al. (2018). Supervised deep learning embeddings for the prediction of cervical cancer diagnosis. Résumé consulté.

Sources consultées le 13 septembre 2026. Bibliographie détaillée et portée des sources dans REFERENCES.md.