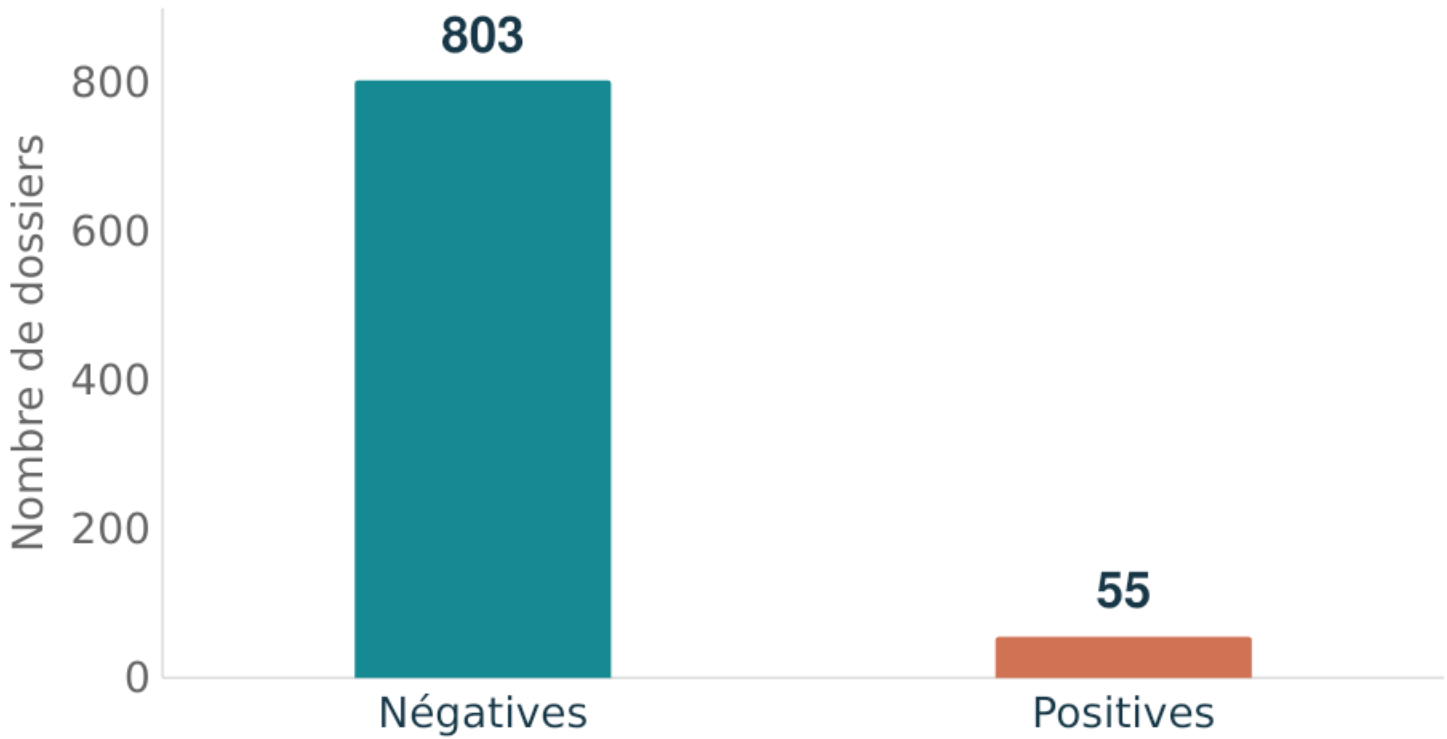
Facteurs de risque cervicaux

Prédire une biopsie positive et explorer les profils de patientes

858 dossiers / 36 variables

Projet Python, UE 5BM753
Régression logistique, forêt aléatoire, PCA et k-means

55 biopsies positives sur 858 dossiers



6,41 %

de biopsies positives

Une référence toujours négative peut sembler très précise.

Résultats calculés sur le CSV fourni. Bibliographie complète dans le rapport.

Un prétraitement lié au scénario

Décision	Motif
Autres examens et Dx exclus	Disponibilité avant la biopsie non garantie
Deux délais d’IST exclus	91,7 % de valeurs manquantes chacun
Médiane ou moyenne + mode	Comparaison dans les plis, avec indicateurs d’absence
log1p et standardisation	Limiter les grandes valeurs et comparer les échelles

Le fichier brut reste intact. Chaque règle est expliquée et traçable.

Un test réservé et cinq plis internes

Sous-ensemble	Lignes	Biopsies positives
Développement	643	41
Test réservé	215	14

Les profils identiques restent du même côté des séparations.

Choix des modèles et seuils dans le développement.
Évaluation finale après fixation de ces choix.

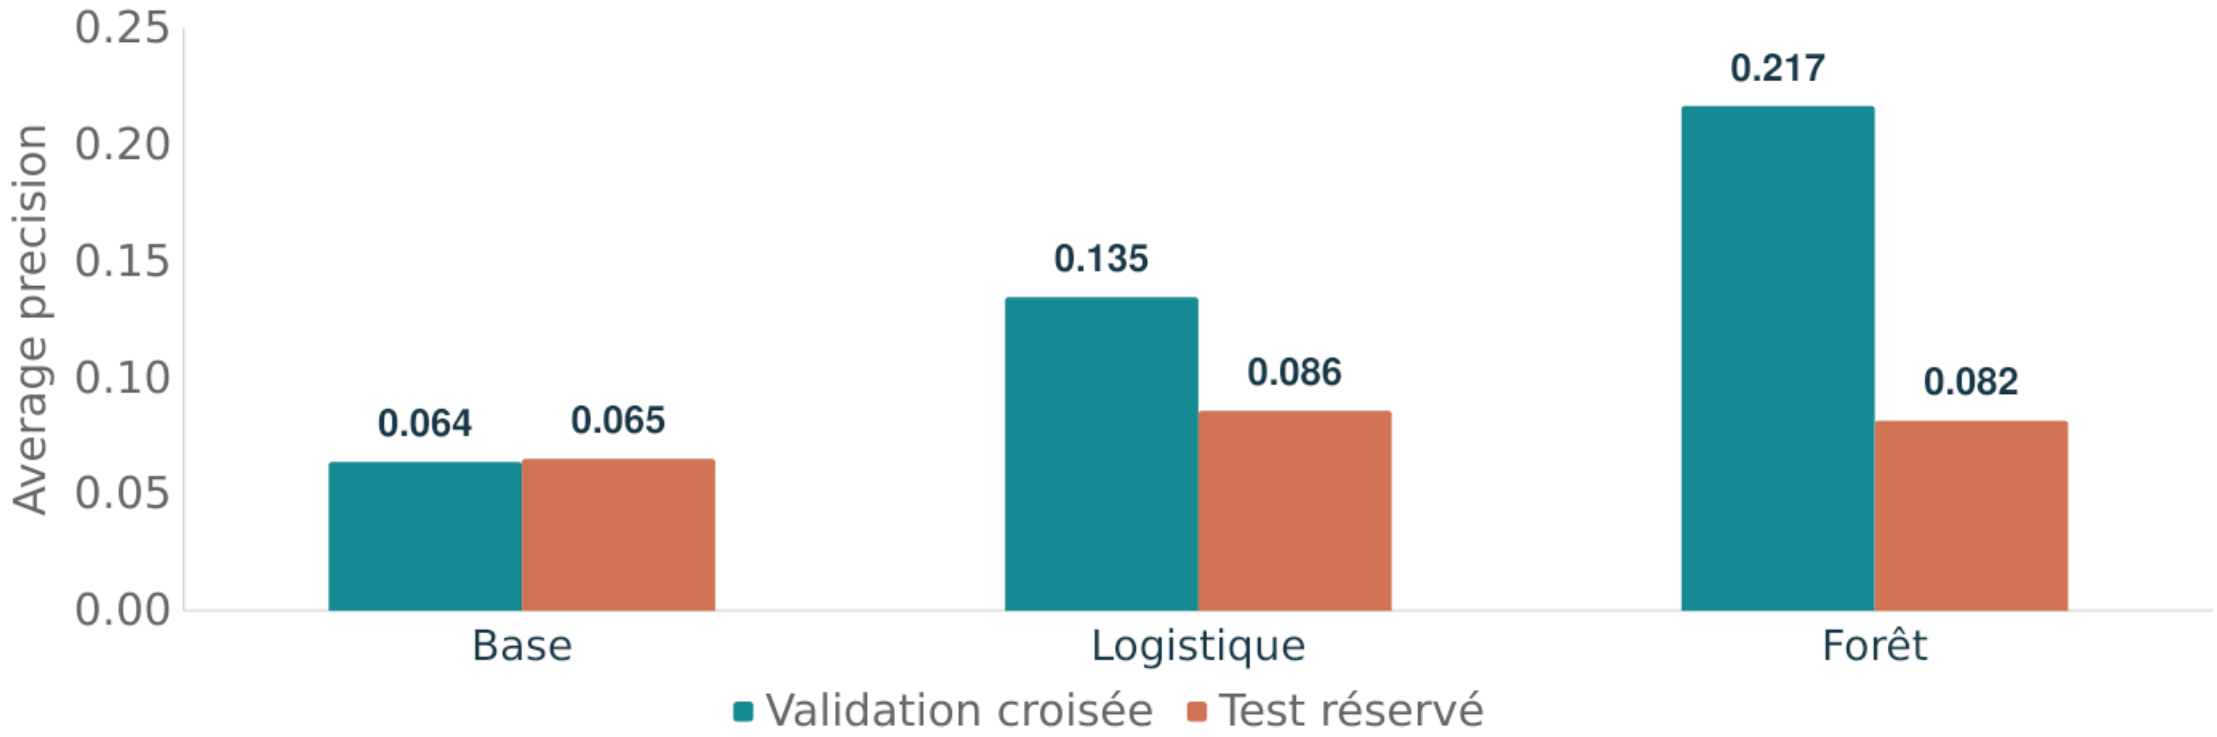
Résultats calculés sur le CSV fourni. Bibliographie complète dans le rapport.

Deux modèles complémentaires

Méthode	Rôle	Complexité limitée
Base naïve	Référence sans facteurs	Même score pour tous
Logistique L2	Effets additifs interprétables	C = 0,1 ou 1
Forêt aléatoire	Seuils et interactions	Profondeur 5, feuilles 5 ou 15

Moyenne/médiane et pondération comparées sur les mêmes plis.
16 configurations au total. Aucun modèle de persistance sans suivi.

La performance chute sur le test



Écart forêt - base sur le test : 0,016.
L’intervalle bootstrap [-0,002 ; 0,087] inclut zéro.

Résultats calculés sur le CSV fourni. Bibliographie complète dans le rapport.

Le seuil ne répare pas le classement

Biopsie observée	Prédite négative	Prédite positive
Négative	173	28
Positive	12	2

2 / 14

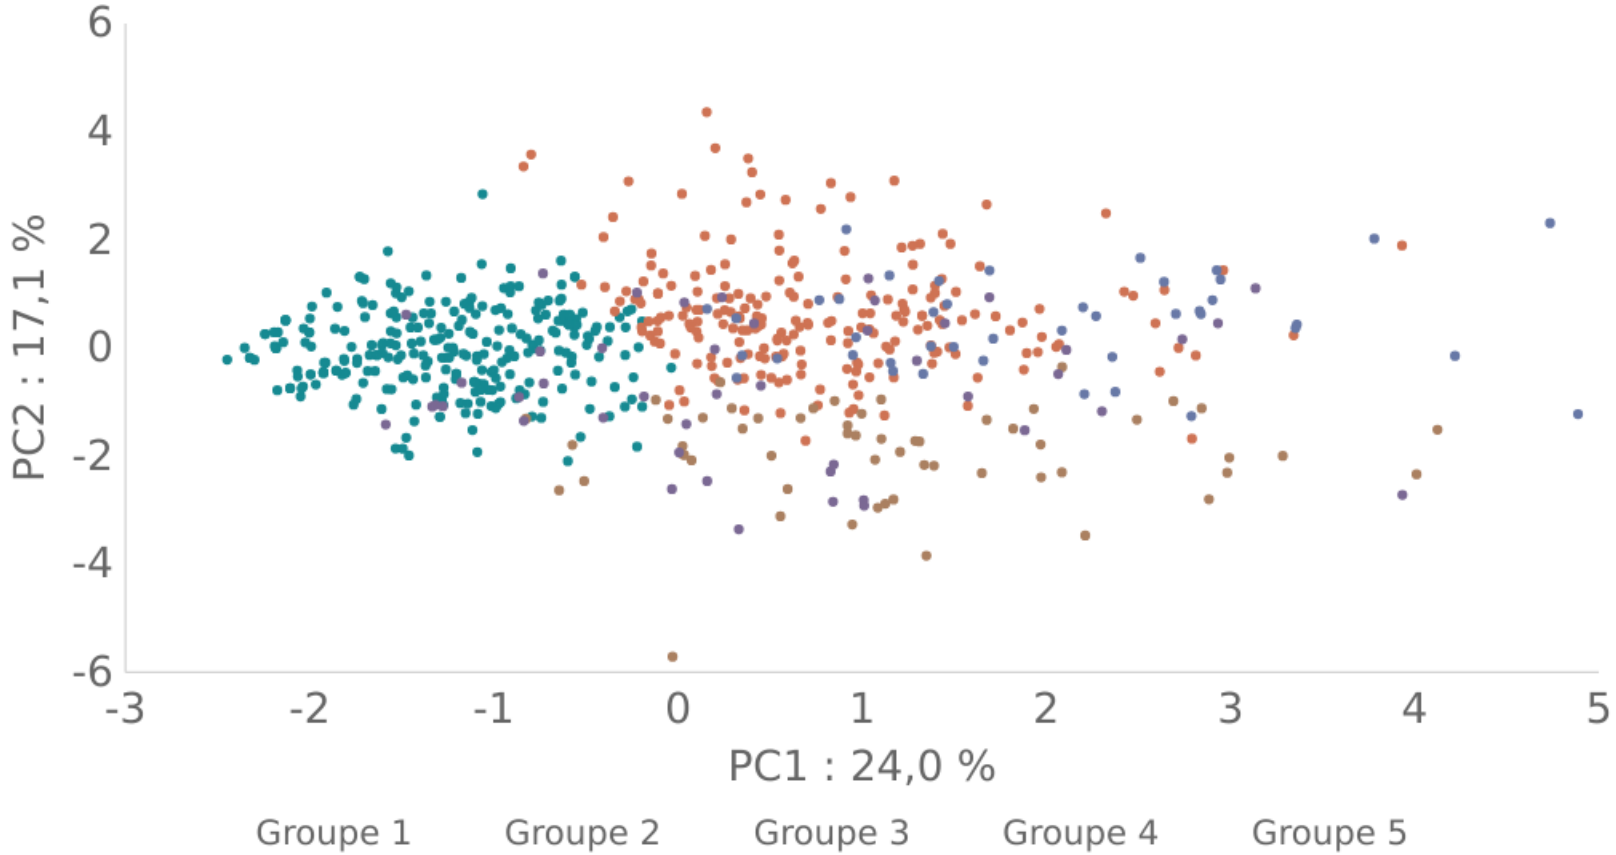
positives détectées

Seuil forêt : 0,116 choisi en développement

Au seuil 0,5 : 93,5 % d’accuracy, mais aucune positive détectée.

Résultats calculés sur le CSV fourni. Bibliographie complète dans le rapport.

La PCA montre 41,2 % de la variance en 2D



8 dimensions

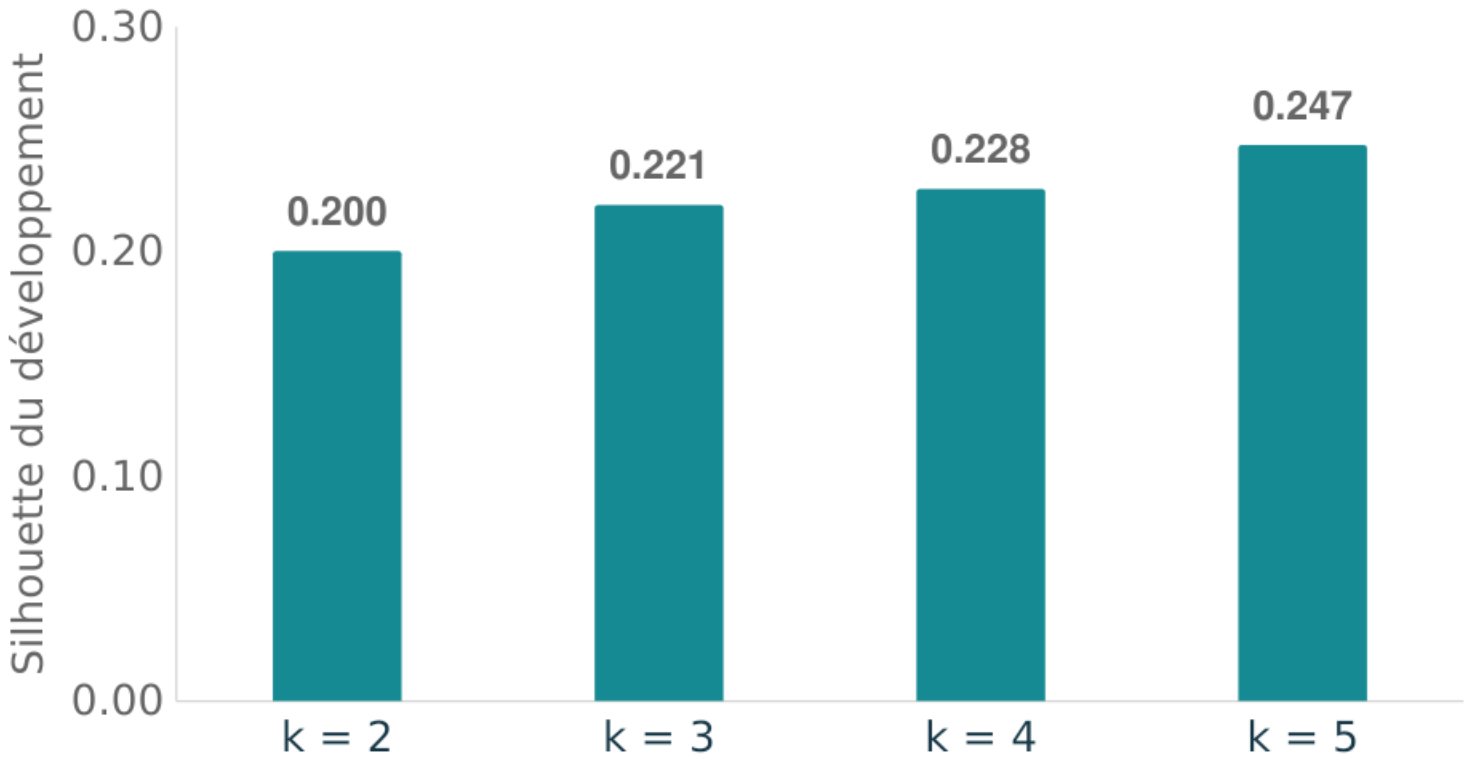
pour le clustering

2 axes pour visualiser

7 axes pour dépasser 90 % de variance

Résultats calculés sur le CSV fourni. Bibliographie complète dans le rapport.

Des groupes stables, mais peu séparés



Silhouette test : 0,232

ARI moyen : 0,954
20 sous-échantillons

Cinq est le meilleur k parmi 2 à 5.

La stabilité ne démontre pas l’existence de classes biologiques nettes.

Résultats calculés sur le CSV fourni. Bibliographie complète dans le rapport.

Ce que les données permettent de conclure

La validation séparée révèle un signal prédictif fragile.

Les groupes décrivent des profils de patientes.
Leurs proportions de biopsies positives restent incertaines.

La suite utile : documenter la cible et la chronologie,
puis évaluer sur de nouvelles données indépendantes.

Résultats calculés sur le CSV fourni. Bibliographie complète dans le rapport.